

Student Analytics UA — Informe metodológico

Fuentes, insumos, estadísticas descriptivas y metodología de la fase previa al acceso a datos institucionales

Proyecto Analítica de Estudiantes — Facultad de Administración y Negocios

2026-09-10

Contenidos

1	Resumen ejecutivo	2
2	Mandato y alcance	2
2.1	Insumos documentales	2
2.2	Compromisos formales	2
2.3	El hallazgo que define el problema	3
3	Fuentes de datos	3
3.1	Fuentes utilizadas	3
3.2	Sobre el identificador MRUN	4
3.3	Fuentes identificadas y no utilizadas todavía	4
3.4	Fuentes de contexto (solo agregadas)	4
4	Estadísticas descriptivas por fuente	5
4.1	Matrícula en Educación Superior (Mineduc / SIES)	5
4.2	Pruebas de admisión PAES (Mineduc / DEMRE)	5
4.3	Trayectoria escolar previa al ingreso	6
4.4	OULAD	7
4.5	Datos sintéticos	7
5	Metodología	8
5.1	Grano analítico	8
5.2	Prevención de fuga temporal	8
5.3	Validación temporal	9
5.4	Cohorte fija	9
5.5	Calibración del generador sintético	9
5.6	Dos objetivos separados	9
5.7	Calidad de la plataforma como propiedad del curso	9
5.8	Ausencia de dato distinta de cero	9
6	Resultados	9
6.1	Retención real de la Universidad Autónoma	9
6.2	Titulación por cohorte de ingreso	10
6.2.1	Censura por derecha: el problema central	11
6.2.2	Un error que las tasas anidadas dejaron a la vista	12
6.3	Piso predictivo de las variables previas al ingreso	12
6.4	Ablación: ¿cuánto sube el piso con la trayectoria escolar completa?	13
6.5	Curva de anticipación sobre OULAD	13
6.6	Curva de anticipación sobre datos sintéticos	14
7	El argumento central	14
8	Limitaciones y supuestos abiertos	14
8.1	Sobre los datos	14
8.2	Sobre el sesgo	15
8.3	Preguntas bloqueantes para la universidad	15

9 Marco legal 15

10 Reproducibilidad 15

! Ninguna cifra de este informe proviene de datos internos de la Universidad Autónoma

Al momento de escribir este documento **el proyecto no tiene acceso a Banner ni a Canvas**. Todo lo que se reporta proviene de tres orígenes: datos abiertos del Ministerio de Educación de Chile, un conjunto de datos público del Reino Unido, y un generador sintético construido para este proyecto.

La única excepción son las cifras de retención de la propia Universidad Autónoma (§ Sección 6.1), que **sí son reales** pero provienen de las bases abiertas de Mineduc, no de sistemas internos.

1 Resumen ejecutivo

Este informe documenta la fase previa al acceso a los datos institucionales. Su propósito no fue construir un modelo, sino **dejar un pipeline cuyo contrato de entrada calce con Banner y Canvas lo bastante bien como para que la migración a datos reales sea un cambio de configuración**, y producir la evidencia que justifica solicitar ese acceso.

Los tres resultados principales:

- 1. **La retención real de la Universidad Autónoma se puede calcular hoy**, desde datos abiertos, cruzando las bases de matrícula por el identificador MRUN. En el área de Administración y Comercio la cohorte 2024 retuvo **84,1%** en la misma carrera. Entre sedes hay una brecha de **14 puntos**.
- 2. **Todo el expediente escolar previo predice poco**. Con 135.050 ingresantes universitarios y validación temporal, un modelo con NEM, ranking, notas de enseñanza media, los cinco puntajes PAES, dependencia del colegio, **asistencia mensual de 4° medio, decil de ingreso oficial, condición de prioritario y tipo de financiamiento** alcanza **AUC 0,636**. Solo la ficha de admisión llega a 0,617; todo el resto suma 0,019.
- 3. **Los datos de comportamiento superan a ese expediente antes del primer mes**. Sobre datos reales de la Open University, un baseline conductual alcanza **AUC 0,697 en la semana 4** — con el 10% del curso transcurrido y sin registro de asistencia.

De ahí se sigue el argumento del proyecto: el valor no está en lo que ya se sabe del estudiante al matricularse, sino en lo que ocurre durante el semestre.

2 Mandato y alcance

2.1 Insumos documentales

El proyecto se apoya en tres documentos, incluidos en docs/:

Documento	Origen	Qué aporta
2026 Postulación FPDA BA v3	Formulario Fondo de Desarrollo Académico, Universidad Autónoma de Chile	El mandato formal: alcance, compromisos e indicadores por mes
AT_informe-final-2	Hofflinger, A. (2020). Universidad de Los Lagos	Benchmark metodológico; el hallazgo que define el problema
Actualiza-Titulos-Grados	Subsecretaría de Educación Superior	Marco sistémico: masificación, heterogeneidad, trayectorias flexibles

2.2 Compromisos formales

La postulación adjudicada compromete plazos concretos:

Compromiso	Plazo
Permisos de acceso a los datos consolidados por la VRA	antes del mes 2
Segmentos de estudiantes obtenidos	antes del mes 3
≥3 algoritmos entrenados, modelo priorizado 1	antes del mes 4
≥3 algoritmos entrenados, modelo priorizado 2	antes del mes 6

Quedan explícitamente **fuera de alcance** las acciones preventivas de las direcciones de carrera y cualquier implementación dentro de Banner.

2.3 El hallazgo que define el problema

El informe de la Universidad de Los Lagos es el antecedente más relevante. Su resultado central:

Con solo datos previos al ingreso (género, etnia, NEM, PSU, ingreso familiar, dependencia), para alcanzar al 80% de los futuros desertores había que intervenir al **80% de los estudiantes**. Incorporando las notas del primer semestre, capturar el 60% requería solo el **20%**.

Y su recomendación explícita fue mejorar la predicción durante el primer semestre incorporando **notas parciales, asistencia y uso de plataformas virtuales**. Este proyecto es la continuación operativa de esa recomendación.

3 Fuentes de datos

3.1 Fuentes utilizadas

Fuente	Grano	Licencia	Rol en el proyecto
Matrícula en Educación Superior 2007–2026	Individual (MRUN)	Datos abiertos de go-bierno	Retención real UA; población de los modelos; cohortes de ingreso del seguimiento longitudinal
Titulados en Educación Superior 2007–2025	Individual (MRUN)	Datos abiertos de go-bierno	Titulación de la promoción que egresa y titulación por cohorte de ingreso
Pruebas de admisión (PAES) 2023, 2024	Individual (MRUN)	Datos abiertos de go-bierno	Variables previas al ingreso
Asistencia anual por estudiante 2022, 2023	Individual (MRUN + RBD), tasa mensual	Datos abiertos de go-bierno	Asistencia de enseñanza media y su pendiente
Alumnos SEP 2022, 2023	Individual (MRUN + RBD)	Datos abiertos de go-bierno	Vulnerabilidad individual: prioritario / preferente
Asignaciones de Becas y Créditos 2023, 2024	Individual (MRUN)	Datos abiertos de go-bierno	Quintil, decil DFE, gratuidad, FSCU, beca de arancel
OULAD	Estudiante × módulo × semana	CC-BY 4.0	Validar la metodología con datos reales de comportamiento
Canvas Data 2 — esquema	Documentación	Pública	Nombres reales de tablas y columnas

Fuente	Grano	Licencia	Rol en el proyecto
Banner ODS Handbook	Documentación	Publicada por Wayne State University	Nombres reales de tablas Banner
Generador sintético	Estudiante × asignatura × semana	Propio	Forma UA completa: sedes, carreras, asistencia, escala 1,0–7,0

Cita de OULAD: Kuzilek, J., Hlosta, M., & Zdrahal, Z. (2017). Open University Learning Analytics dataset. *Scientific Data*, 4, 170171.

3.2 Sobre el identificador MRUN

Las bases de Mineduc están desagregadas **a nivel individual** y usan MRUN, un identificador ficticio pero **estable entre bases y años**, que permite seguir la trayectoria de una persona desde prekínder hasta doctorado. Chile es de los pocos países OCDE que publica esto abiertamente.

⚠ MRUN no se puede unir a Banner

MRUN es un RUT enmascarado y no existe tabla de equivalencia pública. **Estas bases no pueden generar features de estudiantes concretos de la UA.** Sirven para calibrar, para benchmarking y para argumentar — no para modelar individuos.

3.3 Fuentes identificadas y no utilizadas todavía

Unibles a estudiantes de la UA por claves **no personales** (RBD del colegio de origen, comuna), y por tanto candidatas legítimas a features:

Fuente	Llave	Feature potencial
JUNAEB — IVE	RBD	Índice de vulnerabilidad del colegio (0–100)
Agencia de Calidad — SIMCE	RBD	Rendimiento histórico del establecimiento
Rendimiento por estudiante	MRUN + RBD	Notas y promoción año a año en enseñanza media
Titulados en Educación Superior	MRUN	Titulación efectiva: el desenlace de largo plazo
Postulaciones a Becas y Créditos	MRUN	Datos FUAS: composición del hogar, ingresos declarados
Matrícula ES (calculado)	RBD	Persistencia en educación superior de los egresados de ese colegio
CASEN	comuna	Contexto socioeconómico

El catálogo completo de datosabiertos.mineduc.cl tiene **48 conjuntos de datos**. La prioridad de incorporación debería guiarse por el resultado de la ablación (§ Sección 6): las variables previas al ingreso ya mostraron rendimientos decrecientes, así que conviene invertir el esfuerzo en los datos institucionales antes que en más fuentes públicas.

Ver § Sección 8 para la razón por la que su incorporación requiere cuidado.

3.4 Fuentes de contexto (solo agregadas)

CNED INDICES, informes SIES, mifuturo.cl, datos.gob.cl. Útiles para benchmarking y acreditación; no aportan al modelamiento.

4 Estadísticas descriptivas por fuente

Una subsección por fuente, con su grano, su cobertura y las variables que el proyecto efectivamente usa. Todas las cifras provienen de `documentacion/datos/`, que `scripts/descriptive_stats.py` regenera desde las bases originales.

4.1 Matrícula en Educación Superior (Mineduc / SIES)

Tabla 1: Volumen de las bases de matrícula en educación superior

	Año	Filas
0	2023	1,341,446
1	2024	1,386,084
2	2025	1,454,252

De la base 2024 (1,386,084 filas), la Universidad Autónoma registra **29,889 matriculados de pregrado**, de los cuales **6,475 son cohorte de ingreso 2024**.

Sedes identificadas: CAMPUS EL LLANO, CAMPUS PROVIDENCIA, CASA CENTRAL (TEMUCO), SEDE TALCA.

Tabla 2: Matriculados 2024 de la UA en el área Administración y Comercio

	Carrera	Matriculados 2024
0	INGENIERIA COMERCIAL	2186
1	AUDITORIA E INGENIERIA EN CONTROL DE GESTION	584
2	INGENIERIA EN ADMINISTRACION	258
3	INGENIERIA EN CONTROL DE GESTION	213

4.2 Pruebas de admisión PAES (Mineduc / DEMRE)

Grano: una fila por inscrito, con `MRUN` y `RBD` del establecimiento de egreso. 130 columnas. Proceso de admisión 2024.

En esta base **el valor 0 significa “no rindió esa prueba”, no “obtuvo cero”**. Tratarlo como puntaje desplaza todas las medias hacia abajo y arruina cualquier modelo; en el pipeline se convierte explícitamente a valor ausente.

Tabla 3: Puntajes y expediente escolar — PAES 2024 (excluyendo a quienes no rindieron)

	Variable	% que rindió	Media	DE	p25	p50	p75
0	Promedio de notas de enseñanza media	98.3%	6.0	0.5	5.5	6.0	6.3
1	Puntaje NEM	98.3%	698.8	151.6	587.0	700.0	816.0
2	Puntaje ranking	98.3%	716.0	165.0	592.0	718.0	849.0
3	PAES Competencia Lectora	88.4%	613.9	132.8	510.0	607.0	707.0
4	PAES Matematica M1	87.4%	603.7	140.9	505.0	576.0	679.0
5	PAES Matematica M2	42.7%	419.9	111.8	348.0	395.0	459.0
6	PAES Historia y Cs. Sociales	49.3%	501.3	128.2	402.0	484.0	587.0
7	PAES Ciencias	61.9%	494.5	107.8	418.0	478.0	546.0

La cobertura es informativa por sí misma: casi todos rinden Competencia Lectora y Matemática M1, pero **solo el 43% rinde Matemática M2** y la mitad rinde Historia. Un modelo que use M2 como predictor lo estará imputando para más de la mitad de los casos.

Tabla 4: Dependencia del establecimiento de egreso

	Dependencia	n	Proporción
0	Particular Subvencionado	164257	53.1%
1	Municipal	55629	18.0%
2	Particular Pagado	32448	10.5%
3	Corporacion Municipal	28545	9.2%
4	Servicio Local de Educacion	13084	4.2%
5	Corp. de Administracion Delegada	10455	3.4%
6	NaN	4932	1.6%

4.3 Trayectoria escolar previa al ingreso

Tres bases adicionales de Mineduc, unidas por **MRUN** al año anterior al ingreso de cada cohorte:

Base	Grano	Variables usadas
Asistencia anual por estudiante	MRUN + RBD, tasa mensual marzo-diciembre	Asistencia anual, pendiente, mínimo, último trimestre
Alumnos SEP	MRUN + RBD	Prioritario, preferente
Asignaciones de Becas y Créditos	MRUN	Quintil, decil DFE, gratuidad, FSCU, beca de arancel

La variable más interesante no es el nivel de asistencia sino su **pendiente**: un estudiante que baja de 95% en marzo a 70% en noviembre de 4° medio ya se estaba desenganchando antes de matricularse. Es el mismo fenómeno que el proyecto busca detectar dentro del semestre.

Tabla 5: Trayectoria escolar — cohorte de ingreso 2024

	Variable	Cobertura	Media	DE	p25	p50	p75
0	asis_em_anual	54.6%	0.8807	0.1131	0.8435	0.9091	0.9548
1	asis_em_pendiente	54.6%	-0.0092	0.0274	-0.0166	-0.0026	0.0041
2	asis_em_min	54.6%	0.6315	0.2849	0.5238	0.7143	0.8421
3	asis_em_ultimo_trimestre	54.6%	0.8541	0.1952	0.8036	0.9286	1.0000
4	quintil_ingreso	70.4%	2.2641	0.7019	2.0000	2.0000	3.0000
5	decil_dfe	70.4%	4.2747	1.2974	4.0000	4.0000	5.0000
6	prioritario	100.0%	0.3852	NaN	NaN	NaN	NaN
7	preferente	100.0%	0.2291	NaN	NaN	NaN	NaN
8	gratuidad	100.0%	0.6190	NaN	NaN	NaN	NaN
9	fscu	100.0%	0.0115	NaN	NaN	NaN	NaN
10	beca_arancel	100.0%	0.1143	NaN	NaN	NaN	NaN

⚠ El CAE no está en estas bases

La base de Asignaciones cubre gratuidad, becas de arancel y el Fondo Solidario de Crédito Universitario. **El CAE lo administra la Comisión Ingresos y se publica por separado.** Incluir una variable `cae` construida desde esta base daría una columna constante en cero y llevaría a concluir que “el CAE no predice” cuando nunca estuvo en los datos.

4.4 OULAD

Métrica	Valor
Estudiantes únicos	28,785
Inscripciones (estudiante × módulo × presentación)	32,593
Módulos	7
Presentaciones	2013B, 2013J, 2014B, 2014J
Regiones (Reino Unido)	13
Entregas evaluadas	173,912

Tabla 6: Distribución del resultado final en OULAD

	Resultado final	n	Proporción
0	Pass	12361	37.9%
1	Withdrawn	10156	31.2%
2	Fail	7052	21.6%
3	Distinction	3024	9.3%

i Nota

OULAD es educación **a distancia** del Reino Unido: no existe registro de asistencia, la escala de notas es 0–100 y los módulos duran ~9 meses. Sus resultados son un **piso** para lo alcanzable en la UA, no una estimación.

4.5 Datos sintéticos

Métrica	Valor
Estudiantes generados	3,000
Asignaturas	72
Inscripciones	41,744
Filas del panel semanal	751,392
Notas parciales	166,976
Nota final media (escala 1,0–7,0)	4.72 (sd 1.24)
Asistencia media	81.5%
Reprobación por nota	20.0%
Reprobación por inasistencia	7.0%
Reprobación total	24.6%

Métrica	Valor
Cursos sin registro de asistencia	16.7%

Tabla 7: Reprobación por perfil latente de estudiante

	Perfil latente	Inscripciones	Reprobación
0	A_high_performer	9876	5.2%
1	B_silent_high	4790	13.2%
2	C_struggling_engaged	7336	14.9%
3	G_recovering	5201	24.2%
4	F_intermittent	6547	36.9%
5	D_academic_risk	4555	39.5%
6	E_disengaging	3439	74.4%

Tabla 8: Reprobación por nivel de dificultad de la asignatura

	Dificultad	Inscripciones	Reprobación
0	disciplinary	20311	23.5%
1	general	6402	21.2%
2	quantitative_core	15031	27.5%

Tabla 9: Distribución sintética por sede

	campus	estudiantes
0	Providencia	909
1	San Miguel	897
2	Talca	580
3	Temuco	614

5 Metodología

5.1 Grano analítico

Todo el pipeline opera sobre **estudiante × asignatura × período**, construido a partir de un panel semanal **estudiante × asignatura × semana**. La elección no es cosmética: un modelo entrenado sobre promedios de cierre no distingue a un estudiante que empezó bien y se cayó de otro que siempre estuvo bajo, y esos dos casos requieren intervenciones opuestas.

5.2 Prevención de fuga temporal

La fuga de información desde el futuro es el error que **no se detecta mirando métricas**: produce modelos con AUC excelente que fracasan en producción, porque en producción el futuro todavía no ocurrió.

Reglas aplicadas:

- Para el scoring de la semana N , solo se usan filas con `week ≤ N`.
- Las notas se filtran por `available_from_week`, **nunca** por `week`. Una nota de la semana 8 cargada con atraso en la semana 10 existe en la base con `week = 8`; usarla en el scoring de la semana 8 sería entrenar con información que en producción no habría estado disponible.
- Ninguna columna del resultado entra al conjunto de features; hay una verificación explícita que falla si ocurre.

- Una tabla ausente produce features ausentes (NaN), nunca ceros.

La verificación es **de invarianza, no de inspección**: se calculan las features de la semana 8, se reemplaza con valores arbitrarios todo dato posterior a la semana 8, y se recalculan. Si algo cambia, el pipeline estaba mirando adelante.

5.3 Validación temporal

Nunca se usa un split aleatorio como criterio principal. Los períodos antiguos entrenan y los recientes testean. Un split aleatorio mezcla cohortes del mismo año entre entrenamiento y prueba, y produce métricas optimistas que no se sostienen sobre una cohorte futura.

5.4 Cohorte fija

Excluir del scoring a quien ya se dio de baja es correcto: no es un caso a predecir. Pero recalculando esa exclusión en cada semana hace que **la población cambie** entre puntos de la curva, y entonces una mejora del AUC podría venir de más información o simplemente de una población distinta.

Por eso la curva de anticipación se calcula sobre una **cohorte fija**, anclada en la última semana de scoring y evaluada igual en todas. Así lo único que varía entre filas es la información disponible.

La diferencia se midió: los deltas de AUC entre ambos modos son $\leq 0,008$, de modo que la pendiente **no** venía del cambio de población. Pero la prevalencia variable (44% $\rightarrow$ 33%) hacía las filas no comparables, y el lift sí se movía.

5.5 Calibración del generador sintético

El generador **no contiene constantes mágicas**. `config/synthetic.yml` declara tasas objetivo y el código resuelve sus parámetros internos por bisección para satisfacerlas. Cambiar el peso de una señal no altera la tasa global de reprobación, lo que permite probar robustez sin recalibrar todo.

El orden causal es deliberado y no invertible:

```
perfil latente → comportamiento semanal → agregados de cierre  
                → riesgo latente → resultado
```

El resultado nunca se sortea primero. Si se hiciera al revés, cualquier modelo obtendría un AUC excelente y no se sabría si es porque el pipeline funciona o porque el generador filtró la respuesta.

5.6 Dos objetivos separados

Se modelan por separado `fail_by_grade` (reprobación por nota) y `fail_by_attendance` (reprobación por inasistencia). Si la universidad reprueba por inasistencia, la asistencia **no es un predictor** de la reprobación: es parcialmente el mecanismo reglamentario que la produce. Mezclarlos genera un modelo que aprendió el reglamento en vez del fenómeno académico.

5.7 Calidad de la plataforma como propiedad del curso

La adopción de Canvas es heterogénea entre docentes. En cursos de baja adopción las features de actividad se emiten como `NULL` explícito, no como cero: sin esto, todo estudiante de un curso cuyo profesor no usa la plataforma aparece como desenganchado.

5.8 Ausencia de dato distinta de cero

Un conteo ausente es un cero real (no hubo tareas, no hubo notas). Un promedio ausente es **desconocido**. Imputar 0 en `mean_grade` equivale a inventar la peor nota posible.

6 Resultados

6.1 Retención real de la Universidad Autónoma

Calculada cruzando Matrícula 2024 con Matrícula 2025 por MRUN. Cohorte de ingreso 2024.

Tabla 10: Retención al segundo año, cohorte 2024

	Población	n	Misma carrera y universidad	Cualquier institución
0	UA - Administración y Comercio	680	84.1%	92.1%
1	UA - todo el pregrado	6475	85.8%	93.7%
2	Todas las universidades del país	153391	82.0%	92.1%

Tabla 11: Retención por sede — área Administración y Comercio, cohorte 2024

	Sede	n	Misma carrera	Cualquier institución
1	CAMPUS PROVIDENCIA	251	88.8%	95.2%
2	CASA CENTRAL (TEMUCO)	173	85.5%	91.9%
3	SEDE TALCA	157	80.9%	91.1%
0	CAMPUS EL LLANO	99	74.7%	85.9%

Tabla 12: Retención por carrera — área Administración y Comercio

	Carrera	n	Misma carrera	Cualquier institución
1	INGENIERIA EN ADMINISTRACION	36	94.4%	100.0%
2	INGENIERIA EN CONTROL DE GESTION	193	87.6%	94.8%
0	INGENIERIA COMERCIAL	451	81.8%	90.2%

💡 Implicación de diseño

La brecha entre la sede con mayor y menor retención supera los **14 puntos**. Con esos tamaños muestrales no es ruido. La sede debe entrar al modelo como variable, no quedarse como filtro del tablero.

6.2 Titulación por cohorte de ingreso

Con la matrícula histórica descargada (2007 en adelante) se puede seguir a cada cohorte de ingreso contra las bases de titulados de los años siguientes, cruzando por MRUN. Esto responde una pregunta que los indicadores transversales no pueden responder: de quienes **entraron** en un año, qué proporción llegó a titularse. La versión transversal describe a la promoción que **egresa** —cuánto se demoró quien sí se tituló— y es una cohorte distinta.

Se mide en tres niveles anidados. La brecha entre el primero y el segundo es cambio de carrera dentro de la misma universidad; entre el segundo y el tercero, traslado a otra institución. **Sin el tercer nivel, todo traslado se contabiliza como fracaso.**

Tabla 13: Titulación por cohorte de ingreso, sistema universitario nacional (plazo = duración nominal + 2 años)

	Cohorte	Ingresantes	Observables	Cobertura	De su carrera	En su universi- dad	En alguna uni- versidad
0	2007	123,088	122,849	99.8%	30.8%	42.7%	47.9%
1	2008	128,642	128,616	100.0%	33.0%	43.2%	48.3%
2	2009	137,962	137,962	100.0%	38.9%	44.8%	49.8%
3	2010	147,862	147,816	100.0%	38.8%	44.3%	48.9%
4	2011	149,954	149,895	100.0%	37.7%	42.6%	47.9%
5	2012	150,290	150,262	100.0%	39.4%	44.0%	49.0%
6	2013	143,917	143,757	99.9%	38.1%	42.8%	47.2%
7	2014	139,376	139,311	100.0%	39.8%	44.2%	48.6%
8	2015	141,102	141,035	100.0%	42.0%	46.7%	51.7%
9	2016	145,859	145,727	99.9%	45.3%	49.3%	54.0%
10	2017	147,300	144,767	98.3%	46.2%	50.2%	54.5%
11	2018	146,189	117,946	80.7%	47.9%	50.5%	54.2%

Tabla 14: Titulación por cohorte de ingreso — Universidad Autónoma de Chile

	Cohorte	Observables	Cobertura	De su carrera	En su universi- dad	En alguna uni- versidad	Años al título
0	2007	3,672	100.0%	39.0%	44.3%	46.6%	5.0
1	2008	4,300	100.0%	41.4%	48.9%	51.4%	4.0
2	2009	4,890	100.0%	43.6%	51.3%	54.4%	5.0
3	2010	5,266	100.0%	40.5%	53.3%	55.7%	5.0
4	2011	4,728	100.0%	46.4%	55.0%	57.8%	5.0
5	2012	5,189	100.0%	51.2%	53.4%	56.6%	5.0
6	2013	4,020	100.0%	49.9%	52.2%	55.2%	5.0
7	2014	3,763	100.0%	53.0%	54.7%	57.5%	5.0
8	2015	4,228	100.0%	58.6%	60.5%	64.0%	5.0
9	2016	5,216	98.0%	57.5%	59.6%	62.2%	5.0
10	2017	5,354	98.0%	60.0%	61.4%	64.7%	5.0
11	2018	4,247	79.8%	—	—	—	—

6.2.1 Censura por derecha: el problema central

Una cohorte sólo puede evaluarse cuando su plazo se cumplió. Una carrera de cinco años con dos de holgura necesita siete años de datos posteriores, y de la cohorte del perfil todavía no se ha titulado nadie. Comparar cohortes sin corregir esto hace que las recientes parezcan catastróficas por el solo hecho de ser recientes.

El tratamiento tiene **dos niveles**, y el segundo apareció al auditar el resultado del primero:

1. **Por estudiante.** Cada ingresante entra al denominador sólo si su propio horizonte —su duración nominal más la holgura— cabe en los datos disponibles. Quien no alcanzó a ser observado ese tiempo queda fuera del denominador, en vez de contarse como si hubiera desertado.

2. **Por institución.** Corregir el tiempo no corrige la **composición**. Cuando quedan pocos años de seguimiento, las carreras largas caen primero, así que una universidad con mucha medicina o ingeniería queda descrita sólo por sus carreras cortas y su tasa sube sin que haya titulado mejor. Se exige que al menos el 90% de los ingresantes de esa institución sea observable; bajo ese umbral la tasa se anula y se conserva la cobertura, que explica por qué.

⚠ Este filtro cambió el resultado de la UA, no sólo la teoría

Sin el piso por institución, la UA aparecía **primera del sistema** en la cohorte 2018 con 70,4% y percentil 98. Esa cohorte tenía 81% de observabilidad nacional pero sólo 80% en la UA, que concentra 15,7% de carreras de seis años o más contra 12,1% del sistema: el filtro le recortaba justamente sus carreras largas. Con el piso aplicado, la última cohorte comparable pasa a ser **2017**, donde la UA marca 61,4% frente a una mediana de 50,9%. Sigue siendo una posición alta, pero es la que resiste auditoría.

La composición de la UA es **más exigente** que la del sistema, no más fácil: 1,1% de sus ingresantes está en carreras de tres años o menos, contra 13,3% nacional. Su ventaja no viene de ofrecer programas cortos.

i Una cohorte común para todas

La cohorte de referencia que se une al perfil es **la misma para todas las universidades**. Si cada una trajera su última cohorte con dato, la más reciente quedaría representada sólo por las que alcanzan a cerrarla —las de carreras cortas— y el benchmark compararía a unas instituciones en un año contra otras en otro. Se exige que la cohorte elegida tenga tasa utilizable en al menos el 80% del sistema.

6.2.2 Un error que las tasas anidadas dejaron a la vista

La primera versión tomaba el primer título por clave y recién después descartaba los anteriores al ingreso. Un título previo de otra carrera ganaba el mínimo y anulaba al estudiante entero, escondiendo el título posterior que sí correspondía a esa cohorte. Como el nivel *sistema* agrega más títulos por persona, se envenenaba más que los otros, y aparecían universidades con titulación en el sistema **menor** que en su propia institución, lo que es imposible por construcción.

El orden correcto es descartar por año **antes** de agregar por clave. La propiedad de anidamiento —carrera $\leq$ universidad $\leq$ sistema— se verifica hoy como test sobre los datos reales, no sólo sobre casos sintéticos.

6.3 Piso predictivo de las variables previas al ingreso

Modelo: regresión logística sobre NEM, ranking, promedio de notas de enseñanza media, puntajes PAES (Competencia Lectora, Matemática M1 y M2, Historia, Ciencias), dependencia del establecimiento, sexo y años desde el egreso. Objetivo: no continuar en la misma carrera al año siguiente.

Tabla 15: Piso predictivo — comparación de esquemas de validación

	Validación	Población	AUC
0	Split aleatorio (una cohorte)	sistema	0.628
1	Split aleatorio (una cohorte)	solo_universidades	0.616
2	Temporal (2023 entrena → 2024 testea)	sistema	0.623
3	Temporal (2023 entrena → 2024 testea)	universidades	0.617

Con validación temporal — cohorte 2023 entrena ($n = 129.512$) y cohorte 2024 testea ($n = 135.050$), sin que ninguna persona ni ningún año aparezca en ambos lados:

Capacidad de revisión	Casos capturados	Sobre azar
Top 5%	9,6%	1,92×
Top 10%	17,6%	1,76×

Capacidad de revisión	Casos capturados	Sobre azar
Top 20%	31,3%	1,57×
Top 50%	63,8%	1,28×

El AUC con validación temporal (0,615) es idéntico al del split aleatorio (0,615). El piso es estable y el resultado se sostiene sobre cohortes futuras.

6.4 Ablación: ¿cuánto sube el piso con la trayectoria escolar completa?

La pregunta que corresponde antes de incorporar variables socioeconómicas a un modelo que prioriza estudiantes no es “¿predicen?” sino “¿cuánto añaden por encima de lo que ya tenemos?”. Población: solo universidades, validación temporal 2023 → 2024.

Tabla 16: Valor incremental de cada bloque de variables previas al ingreso

	Modelo	N° features	AUC	Δ vs base	Top 20%
0	A. Ficha de admisión (base)	14	0.617	+0.000	31.6%
1	B. Base + asistencia de ens. media	18	0.622	+0.005	32.2%
2	C. Base + socioeconómico	21	0.631	+0.014	33.2%
3	D. Base + ambos	25	0.636	+0.019	33.8%
4	E. Solo asistencia de ens. media	4	0.543	-0.073	26.9%

Tres lecturas:

La asistencia de enseñanza media aporta +0,005. Esto no contradice a ULagos: lo que ese informe mostró es que la asistencia importa *dentro* de la institución y del período en curso. Como rasgo que se arrastra a través de una transición institucional, casi no transfiere — de hecho, **usada sola alcanza AUC 0,543**, apenas sobre el azar.

Las variables socioeconómicas aportan +0,014. Es poco, y ese “poco” resuelve empíricamente el dilema ético: excluirlas del scoring cuesta casi nada en desempeño. La decisión de usarlas o no deja de ser un intercambio entre equidad y precisión.

Todo junto llega a 0,636. Con el expediente escolar íntegro —asistencia mensual, decil de ingreso oficial, condición de prioritario, tipo de financiamiento— el piso sigue por debajo de lo que un baseline conductual alcanza en la semana 4.

6.5 Curva de anticipación sobre OULAD

Tabla 17: Poder predictivo vs anticipación — OULAD, cohorte fija

	Semana	AUC	Top 10%	Top 20%	Semanas restantes
0	4	0.697	15.5%	33.6%	35
1	8	0.753	19.4%	37.5%	31
2	12	0.801	26.4%	43.6%	27
3	16	0.824	27.7%	45.9%	23
4	20	0.840	27.7%	46.5%	19
5	26	0.859	29.0%	48.7%	13

6.6 Curva de anticipación sobre datos sintéticos

Tabla 18: Poder predictivo vs anticipación — datos sintéticos

	Semana	AUC	Top 10%	Top 20%	Semanas restantes
0	3	0.652	14.8%	28.9%	15
1	5	0.681	16.5%	30.9%	13
2	8	0.717	19.2%	36.3%	10
3	12	0.749	22.3%	41.5%	6

Estas cifras **no son un hallazgo**: miden que el pipeline recupera la señal que el propio generador inyectó, y que la dificultad del problema simulado está en el rango que reporta la literatura.

7 El argumento central

Poniendo los dos resultados reales uno junto al otro:

Modelo	Datos	n	AUC
Ficha de admisión	PAES + Matrícula, validación temporal	135.050	0,617
Expediente escolar completo	1. asistencia mensual, decil DFE, SEP, financiamiento	135.050	0,636
Comportamiento, semana 4	OULAD, 10% del curso, sin asistencia	13.144	0,697
Comportamiento, semana 12	OULAD, 31% del curso, sin asistencia	13.144	0,801

Todo lo que el Estado de Chile sabe de un estudiante antes de que pise la universidad —NEM, ranking, cinco pruebas PAES, dependencia del colegio, asistencia mensual de 4° medio, decil de ingreso oficial, condición de prioritario, tipo de financiamiento— alcanza **AUC 0,636**.

Un baseline conductual lo supera con el **10% del curso transcurrido**, y sin siquiera disponer de asistencia —justamente la variable que el informe ULagos identificó como clave.

Ese es el caso para solicitar acceso a Banner y Canvas: **el valor no está en lo que ya se sabe del estudiante al matricularse**.

8 Limitaciones y supuestos abiertos

8.1 Sobre los datos

- **Cobertura del cruce PAES.** Solo el 53% de los ingresantes 2024 aparece en PAES 2024: quienes entran a IP/CFT o por vías alternativas no la rinden. La población analizada son ingresantes con PAES, que es el perfil relevante para la UA pero no describe al sistema completo.
- **OULAD no tiene asistencia.** Sus resultados son un piso.
- **OULAD no registra fecha de corrección**, solo de entrega. Se asume disponibilidad inmediata, lo cual es optimista.
- **Los datos sintéticos no son evidencia** sobre estudiantes reales.

8.2 Sobre el sesgo

Las fuentes unibles por RBD (IVE, SIMCE, dependencia) son **proxies de nivel socioeconómico**. Un modelo que marque en rojo a estudiantes de colegios vulnerables *antes de observar conducta alguna* no detecta riesgo: reproduce desigualdad.

La recomendación fue someterlas a una prueba de **valor incremental**, y esa prueba ya se corrió (§ Sección 6): las variables socioeconómicas —quintil, decil DFE, prioritario, financiamiento— aportan **+0,014 de AUC** sobre la ficha de admisión.

Eso convierte una discusión ética en una decisión barata: **excluir las del scoring cuesta casi nada en desempeño**. La recomendación operativa es usarlas para el análisis de equidad y para dimensionar la focalización, y mantenerlas fuera del modelo que prioriza estudiantes. La decisión final es de la universidad, no técnica, y conviene plantearla en el mismo taller donde se prioricen los casos de uso.

8.3 Preguntas bloqueantes para la universidad

Tres cambian el diseño del pipeline:

1. ¿Usa la UA el módulo **Banner Attendance Tracking**? Es opcional. Sin él solo existe `SFRSTCR_LAST_ATTEND`, que no entrega grano semanal.
2. ¿Existen **notas parciales fechadas**, o solo la nota final del período?
3. ¿Contempla el reglamento la **reprobación por inasistencia**, y con qué umbral?

El contrato completo de datos, con el nivel de confianza de cada campo, está en `config/data_contracts.yml`.

9 Marco legal

La **Ley 21.719** de Protección de Datos Personales entra en plena vigencia el **1 de diciembre de 2026**, dentro del horizonte de este proyecto. Consagra el derecho a no ser objeto de decisiones basadas exclusivamente en tratamiento automatizado, incluido el perfilamiento, con garantías de **explicación, intervención humana y revisión**.

Consecuencias de diseño, no de cumplimiento:

1. El humano en el circuito deja de ser buena práctica y pasa a ser requisito: el modelo prioriza, la dirección de carrera decide.
2. La explicabilidad por caso deja de ser opcional.
3. Conviene levantar base de licitud y evaluación de impacto con la Dirección Jurídica **antes** de que el modelo toque datos reales.

10 Reproducibilidad

Todas las cifras de este informe se regeneran con:

```
python -m venv .venv && .venv\Scripts\activate
pip install -e ".[modeling,ui,dev]"

python scripts/generate_synthetic.py
python scripts/download_oulad.py
python scripts/download_mineduc.py
python scripts/analyze_mineduc.py
python scripts/validate_lead_time.py --source synthetic --out data/results
python scripts/validate_lead_time.py --source oulad --out data/results
python scripts/descriptive_stats.py

quarto render documentacion/informe_metodologico.qmd
```

El generador sintético es determinista dado su semilla (`config/synthetic.yml: seed`). La suite de pruebas incluye una verificación de reproducibilidad que falla si dos ejecuciones con la misma semilla difieren.

Python 3.11.9
Plataforma Windows 10
pandas 3.0.5
Generado 2026-09-10 12:04